



## Rapport de projet : Rectangle Tree

Hugo Charels 000544051      Mickael Kovel 000396950

28 Avril 2023

# Contents

<b>1</b>	<b>Introduction</b>	<b>3</b>
<b>2</b>	<b>Structure</b>	<b>3</b>
<b>3</b>	<b>Création</b>	<b>4</b>
3.1	Split quadratique . . . . .	5
3.1.1	Pick Seed . . . . .	5
3.1.2	Pick Next . . . . .	6
3.2	Split linéaire . . . . .	6
3.2.1	Pick Seed . . . . .	7
3.2.2	Pick Next . . . . .	7
<b>4</b>	<b>Recherche</b>	<b>8</b>
<b>5</b>	<b>Expériences sur donnees réelles</b>	<b>8</b>
5.1	Belgique - Secteurs statistiques . . . . .	8
5.2	France - Communes . . . . .	8
5.3	Monde - Pays . . . . .	8
5.4	Monde - Villes . . . . .	8
5.5	Analyse . . . . .	8
<b>6</b>	<b>Conclusion</b>	<b>8</b>
<b>7</b>	<b>Références bibliographiques</b>	<b>8</b>

# 1 Introduction

Dans de nombreuses applications, la manipulation de polygones est essentielle. Ces polygones peuvent représenter des régions administratives, des informations géologiques, des zones de dessins vectoriels ou encore des images médicales. Lorsqu'il s'agit de déterminer à quel polygone appartient un point donné, une question se pose : comment résoudre efficacement le problème du "Point in Polygon" (PIP) ?

L'algorithme PIP, connu depuis 1962, consiste à compter le nombre de fois qu'une demi-droite partant du point traverse une arête du polygone. Si ce nombre est pair, le point est à l'extérieur du polygone, sinon, il est contenu à l'intérieur. Cependant, si l'on a des milliers de polygones complexes à tester avec un grand nombre de points, une méthode naïve devient inefficace.

Une première optimisation consiste à utiliser l'enveloppe ou "minimum bounding rectangle" (MBR), qui est le plus petit rectangle horizontal englobant totalement le polygone. Avant d'appliquer l'algorithme PIP, on vérifie d'abord l'inclusion du point dans le MBR, ce qui permet de réduire le nombre d'appels à PIP.

Cependant, lorsque le nombre de polygones et de MBR est élevé, une approche hiérarchique basée sur l'algorithme R-Tree devient pertinente. En regroupant les MBR de manière optimale, on peut éviter de considérer tous les MBR pour chaque point à tester.

Dans ce projet, nous allons implémenter et évaluer deux variantes de l'algorithme R-Tree (quadratique et linéaire) pour résoudre efficacement le problème du PIP. Nous testerons ces variantes avec différents paramètres pour évaluer leurs performances.

Le rapport détaillera la méthodologie utilisée, les résultats obtenus et une analyse approfondie des performances des variantes de l'algorithme R-Tree. Nous discuterons également des défis rencontrés et des perspectives pour de futures recherches.

En conclusion, ce projet vise à résoudre efficacement le problème du PIP en utilisant l'algorithme R-Tree. Les résultats obtenus nous permettront de déterminer la meilleure variante en fonction des paramètres et de formuler des recommandations pour d'éventuelles améliorations.

# 2 Structure

Dans cette section, nous allons explorer la structure d'un R-Tree, une arborescence utilisée pour organiser efficacement les données géospatiales et résoudre le problème du "Point in Polygon" (PIP). L'objectif est de comprendre comment cette structure hiérarchique permet de regrouper les MBR (minimum bounding rectangles) de manière optimale.

Un R-Tree est une structure de données arborescente utilisée pour l'indexation spatiale des objets géométriques. Il est conçu pour stocker et organiser efficacement des données multidimensionnelles, telles que des polygones, des points ou

des rectangles.

L'idée fondamentale d'un R-Tree est de regrouper les MBR de manière hiérarchique. Chaque nœud de l'arbre représente un MBR, qui peut être un polygone ou un rectangle englobant un groupe de MBR plus petits.

- Nœuds internes : Les nœuds internes de l'arbre contiennent des MBR qui englobent plusieurs autres MBR. Ils servent de guides pour naviguer dans la structure et réduire la recherche de MBR pertinents lors de la résolution du problème du PIP.
- Feuilles : Les nœuds feuilles de l'arbre contiennent les MBR individuels et sont généralement associés à des objets géométriques spécifiques. Ils sont utilisés pour effectuer les tests d'inclusion du point lors de la résolution du PIP.

L'algorithme R-Tree utilise des critères spécifiques pour regrouper les MBR de manière optimale. Ces critères visent à maximiser la compacité des groupes de MBR et minimiser leur superposition avec d'autres groupes.

- Critère de regroupement spatial : Les MBR ayant une proximité spatiale élevée sont regroupés ensemble pour réduire la recherche dans les parties de l'arbre non pertinentes pour le point en cours d'évaluation.
- Critère de compacité : Lorsque plusieurs MBR sont candidats pour un regroupement, celui qui crée le MBR englobant le plus compact est préféré. Cela garantit une meilleure utilisation de l'espace de stockage et une réduction des opérations de recherche.

Nous détaillerons la recherche d'un point dans un R-Tree dans la section 4.

### 3 Création

Dans cette section, nous allons aborder la création d'un R-Tree, en expliquant les étapes de base pour construire cette structure hiérarchique. Nous présenterons également deux algorithmes de construction : le split quadratique et le split linéaire.

La création d'un R-Tree implique de regrouper les MBR de manière hiérarchique. Pour cela, nous commençons avec un ensemble de MBR individuels et suivons un processus de division et de regroupement pour former l'arbre.

L'algorithme de construction de base utilise deux étapes principales : le split et le picknext. Le split consiste à diviser un groupe de MBR en deux groupes plus petits, tandis que le picknext sélectionne le prochain MBR à insérer dans l'arbre.

Il existe deux variantes d'algorithmes de split : le split quadratique et le split linéaire. Explorons-les plus en détail.

### 3.1 Split quadratique

Le split quadratique est un algorithme de division utilisé dans la construction d'un R-Tree. Il se base sur le concept de compacité des MBR pour choisir les MBR à diviser.

L'idée du split quadratique est de sélectionner deux MBR initiaux qui sont le plus éloignés possible. Pour cela, nous calculons toutes les paires possibles de MBR et choisissons celle qui dont l'aire d'encadrement est la plus grande.

Avantages du split quadratique :

- Il tend à créer une structure plus équilibrée en termes de taille des nœuds et de compacité des MBR.
- Il est moins susceptible de générer des feuilles surchargées ou des nœuds internes avec peu de MBR.

Inconvénients du split quadratique :

- Il peut être plus coûteux en termes de temps de calcul, car il nécessite l'évaluation de toutes les paires de MBR possibles.

#### 3.1.1 Pick Seed

Dans le contexte du split quadratique, le pickseed est l'algorithme utilisé pour choisir les deux MBR initiaux à diviser.

L'algorithme du pickseed consiste à énumérer toutes les paires possibles de MBR et à sélectionner celle qui a l'aire d'encadrement la plus grande.

L'objectif est de trouver les deux MBR qui englobent l'espace maximal, formant ainsi une base solide pour la construction ultérieure de l'arbre.

```
protected AbstractNodePair pickSeeds(Node node) {
    AbstractNodePair nodes = new AbstractNodePair(node.getChild(0),
                                                    node.getChild(1));

    MBR biggest = nodes.n1.getMBR().getUnion(nodes.n2.getMBR());
    for (int i = 1; i < node.getChildren().size(); i++) {
        for (int j = i + 1; j < node.getChildren().size(); j++) {
            if (i==j) { continue; }
            MBR union = node.getChild(i).getMBR().getUnion(node.getChild(j).getMBR());
            if (union.getArea() > biggest.getArea()) {
                nodes.n1 = node.getChild(i);
                nodes.n2 = node.getChild(j);
                biggest = union;
            }
        }
    }
    return nodes;
}
```

### 3.1.2 Pick Next

Après avoir choisi les deux MBR initiaux, le picknext est utilisé pour sélectionner le prochain MBR à insérer dans l'arbre lors du processus de construction.

L'algorithme du picknext consiste à évaluer l'augmentation d'aire résultant de l'ajout de chaque MBR restant au premier groupe. Le MBR qui entraîne la plus petite augmentation d'aire est choisi comme prochain MBR à insérer.

Ce processus est répété jusqu'à ce que tous les MBR soient attribués à un groupe.

```
private void pickNext(Node n1, Node n2, List<AbstractNode> children) {
    for (AbstractNode child : children) {
        if (n1.getMBR().getExpansion(child.getMBR()) <
            n2.getMBR().getExpansion(child.getMBR())) {
            n1.addChild(child);
            n1.expandMBR(child.getMBR());
        }
        else {
            n2.addChild(child);
            n2.expandMBR(child.getMBR());
        }
    }
}
```

### 3.2 Split linéaire

Le split linéaire est un autre algorithme de division utilisé dans la construction d'un R-Tree. Il ne prend pas en compte la compacité des MBR lors de la sélection des MBR à diviser, mais se base sur la position des MBR. Ce qui permet de réduire le temps de calcul.

Le split linéaire est une autre variante de l'algorithme de division utilisé dans la construction d'un R-Tree. Contrairement au split quadratique, il ne prend pas en compte la compacité des MBR lors de la sélection des MBR à diviser mais se base sur la position relative des MBR les uns par rapport aux autres. Ce qui permet de réduire le temps de calcul.

L'idée du split linéaire est de sélectionner deux MBR initiaux qui sont le plus extrêmes possible.

Avantages du split linéaire :

- Il est plus rapide que le split quadratique, car il ne nécessite pas l'évaluation de toutes les paires de MBR possibles.
- Il est plus simple à implémenter.

Inconvénients du split linéaire :

- Il tend à créer une structure moins équilibrée en termes de taille des nœuds et de compacité des MBR.
- Il est plus susceptible de générer des feuilles surchargés ou des nœuds internes avec peu de MBR.

### 3.2.1 Pick Seed

Le pickseed (linéaire) est utilisé pour sélectionner les deux MBR initiaux dans le contexte du split linéaire. Il s'agit simplement d'attribuer les deux premiers MBR rencontrés à chaque groupe.

```
protected AbstractNodePair pickSeeds(Node node) {
    List<AbstractNode> children = new java.util.ArrayList<>(node.getChildren());

    AbstractNode nodeMinOfMaxX = children.stream().min(
        Comparator.comparingDouble(n -> n.getMBR().getXMax())).orElse(null);
    AbstractNode nodeMaxOfMinX = children.stream().max(
        Comparator.comparingDouble(n -> n.getMBR().getXMin())).orElse(null);
    AbstractNode nodeMinOfMaxY = children.stream().min(
        Comparator.comparingDouble(n -> n.getMBR().getYMax())).orElse(null);
    AbstractNode nodeMaxOfMinY = children.stream().max(
        Comparator.comparingDouble(n -> n.getMBR().getYMin())).orElse(null);

    double smallDistX = nodeMaxOfMinX.getMBR().getXMax() - nodeMinOfMaxX.getMBR().getXMin();
    double bigDistX = nodeMaxOfMinX.getMBR().getXMin() - nodeMinOfMaxX.getMBR().getXMax();
    double smallDistY = nodeMaxOfMinY.getMBR().getYMax() - nodeMinOfMaxY.getMBR().getYMin();
    double bigDistY = nodeMaxOfMinY.getMBR().getYMin() - nodeMinOfMaxY.getMBR().getYMax();
    if (smallDistX/bigDistX > smallDistY/bigDistY)
        return new AbstractNodePair(nodeMinOfMaxX, nodeMaxOfMinX);
    else
        return new AbstractNodePair(nodeMinOfMaxY, nodeMaxOfMinY);
}
```

### 3.2.2 Pick Next

Le picknext (linéaire) est utilisé pour sélectionner le prochain MBR à insérer dans l'arbre lors de la construction. Il suffit de choisir le prochain MBR dans l'ordre de leur apparition lors du parcours.

```
private void pickNext(Node n1, Node n2, List<AbstractNode> children) {
    for (AbstractNode child : children) {
        if (n1.getMBR().getExpansion(child.getMBR()) <
            n2.getMBR().getExpansion(child.getMBR())) {
            n1.addChild(child);
            n1.expandMBR(child.getMBR());
        }
    }
}
```

```

    }
    else {
        n2.addChild(child);
        n2.expandMBR(child.getMBR());
    }
}
}

```

## 4 Recherche

## 5 Expériences sur données réelles

ici on va écrire les expériences sur données réelles

### 5.1 Belgique - Secteurs statistiques

ici on va écrire les expériences sur les secteurs statistiques

### 5.2 France - Communes

ici on va écrire les expériences sur les communes

### 5.3 Monde - Pays

ici on va écrire les expériences sur les pays

### 5.4 Monde - Villes

ici on va écrire les expériences sur les villes

### 5.5 Analyse

ici on va écrire l'analyse

## 6 Conclusion

ici on va écrire la conclusion

## 7 Références bibliographiques

ici on va écrire les références bibliographiques